



PROJEKT 9: ROZPOZNAWANIE STYLU OBRAZÓW

Sebastian Borukało (-----)

Jakub Bukała (-----)

Jakub Smakowski (-----)

Opiekun: Dr inż. Piotr Duch

AGENDA

- Przedstawienie założeń projektu
- Wybór bazy danych
- Schemat działania algorytmu
- Przegląd literatury
- Omówienie wybranych filtrów
- Otrzymane wyniki
- Podjęte kroki
- Nowe wyniki + omówienie
- Podsumowanie

PROJEKT 9: ROZPOZNAWANIE STYLU OBRAZÓW

GŁÓWNY CEL:

- opracowanie i zaimplementowanie **algorytmu do automatycznego rozpoznawania stylu obrazów** na podstawie ich cech wizualnych.

EFEKT KOŃCOWY:


- **Klasyfikacja** obrazu do określonej **kategorii artystycznej** (np. impresjonizm, kubizm, surrealizm).
- **Porównanie** obrazu pod kątem podobieństwa stylistycznego.

ZAKRES DZIAŁANIA (WYMAGANIA):

1. Algorytm musi **automatycznie analizować i ekstrahować charakterystyczne cechy stylu** z obrazu.
2. System musi **porównać zidentyfikowane cechy z bazą danych stylów**.


OGRANICZENIA TECHNOLOGICZNE:

Rozwiązanie **nie może wykorzystywać sieci neuronowych**, ale może używać różnorodnych technik przetwarzania obrazów i uczenia maszynowego




BAZA DANYCH

	steubk/wikiart (Kaggle)
Liczba obrazów	~80,020
Liczba unikalnych stylów artystycznych	27
Format plików/ Rozdzielczość	JPG Zmienna rozdzielczość
Rozkład klas	Nierównomierny



SCHEMAT ALGORYTMU



Pobieranie obrazów z bazy danych

Pobranie obrazów z bazy danych i przypisanie im odpowiednich etykiet stylu (np. Kubizm, Impresjonizm).




Wstępny okrojony preprocessing

Resize do **rozdzielczości 512x512** w celu optymalizacji obliczeń i standaryzacji rozmiaru



Ekstrakcja cech


Ekstrakcja Cech Koloru, Tekstury, Kształtu i Krawędzi. Konkatenacja Wektorów Cech



Ekstrakcja cech (zapis) + PCA

Połączenie wszystkich wyekstrahowanych cech w jeden finalny wektor cech dla każdego obrazu.

Użycie PCA (dopasowanego do zbioru treningowego) w celu znalezienia najważniejszych składowych.



Klasyfikator SVM

Wytrenowanie (lub użycie) klasyfikatora na zredukowanych wektorach cech i etykietach ze zbioru treningowego.

PRZEGLĄD LITERATURY



Datta, R., Joshi, D., Li, J., Wang, J.Z. (2006), "Studying Aesthetics in Photographic Images Using a Computational Approach": https://link.springer.com/chapter/10.1007/11744078_23#preview

[Barwność i Nasycenie ; Momenty kolorów ; Harmonia i kontrast kolorów ; Statystyki konturów]



Karayev, S., Trentacoste, M., Han, H., Agarwala, A., Darrell, T., Hertzmann, A., & Winnemoeller, H. (2014), "Recognizing Image Style": <https://arxiv.org/pdf/1311.3715>

[HOG ; LBP ; Filtry Gabora (GIST) ; Momenty kolorów]



Misumi, M., Orii, H., Sharmin, T., Mishima, K., & Tsuruoka, T. (2016), "Image classification for the painting style with SVM": <https://pdfs.semanticscholar.org/70f0/3f20e91bfdc6c27fbb4fef5f3aa5883c24af.pdf>

[LBP ; HOG ; Momenty kolorów]



Hallur, S., & Gavade, A. (2025), "Image Feature Extraction Techniques: A Comprehensive Review": https://www.researchgate.net/publication/395782910_Image_Feature_Extraction_Techniques_A_Comprehensive_Review

[LBP ; Cechy Haralicka (GLCM) ; Filtry Gabora ; HOG ; Momenty kolorów]



T. Kowaliw, J. McCormack and A. Dorin (2010), "Evolutionary Automated Recognition and Characterization of an Individual's Artistic Style": [Evolutionary_Automated_Recognition_and_Characteriz.pdf](#)

[Wymiar fraktalny ; Entropia obrazu ; Widmo mocy radialnej ; Podsumowanie widma radialnego]


WYKORZYSTANE FILTRY

- **LBP (Local Binary Patterns)** – histogram jednolitych wzorców binarnych (analiza mikrotekstur).
- **Symetria strukturalna (SSIM)** – obliczanie symetrii pionowej i poziomej obrazu.
- **Entropia obrazu (Shannon Entropy)** – miara złożoności informacji zawartej w histogramie.
- **Widmo mocy radialnej (Radial Power Spectrum)** – rozkład energii obrazu w zależności od promienia w dziedzinie częstotliwości.
- **Momenty kolorów (Color Moments)** – średnia, wariancja i skośność dla każdego kanału RGB.
- **Barwność i Nasycenie (Colorfulness & Saturation)** – metryka barwności Haslera-Süsstrunka oraz średnie nasycenie z modelu HSV.
- **Harmonia i kontrast kolorów** – kontrast między kanałami (odchylenie różnic) oraz nakładanie się histogramów kanałów (RGB).
- **Statystyki konturów** – liczba obiektów, średnia długość, pole powierzchni i proporcje (aspect ratio) obwiedni.
- **Cechy Haralicka (GLCM)** – statystyki macierzy współwystępowania (kontrast, dyssymilary, homogeniczność, energia, korelacja, ASM).
- **Filtry Gabora** – odpowiedzi filtrów teksturowych dla różnych częstotliwości i kątów orientacji.
- **HOG (Histogram of Oriented Gradients)** – histogram zorientowanych gradientów (często używany do detekcji kształtów).
- **Podsumowanie widma radialnego (Spectral Summary)** – nachylenie widmowe (Spectral Slope) oraz stosunek energii niskich do wysokich częstotliwości.
- **Wymiar fraktalny (Fractal Dimension)** – estymacja złożoności geometrycznej metodą pudełkową (box-counting).

ETAP I

POCZĄTKOWY ZESTAW FILTRÓW – WSZYSTKIE KLASY

Model A
(Wszystkie klasy):
Dokładność (Accuracy):
36.76%




ETAP I

POCZĄTKOWY ZESTAW FILTRÓW – REDUKCJA LICZBY KLAS

Model B
(Redukcja rzadkich
klas < 2.5%):
**Dokładność
(Accuracy): 38.17%.**

Małe klasy zostały
zgrupowane do jednej,
co nieznacznie
poprawiło wynik.



ETAP 2

NOWE FILTRY

Podjęte kroki w tym etapie:

- Research naukowy:

- Dobór nowych ekstraktorów na podstawie artykułów naukowych, które testowały skuteczność algorytmów ML

- Dodanie nowych filtrów, takich jak:

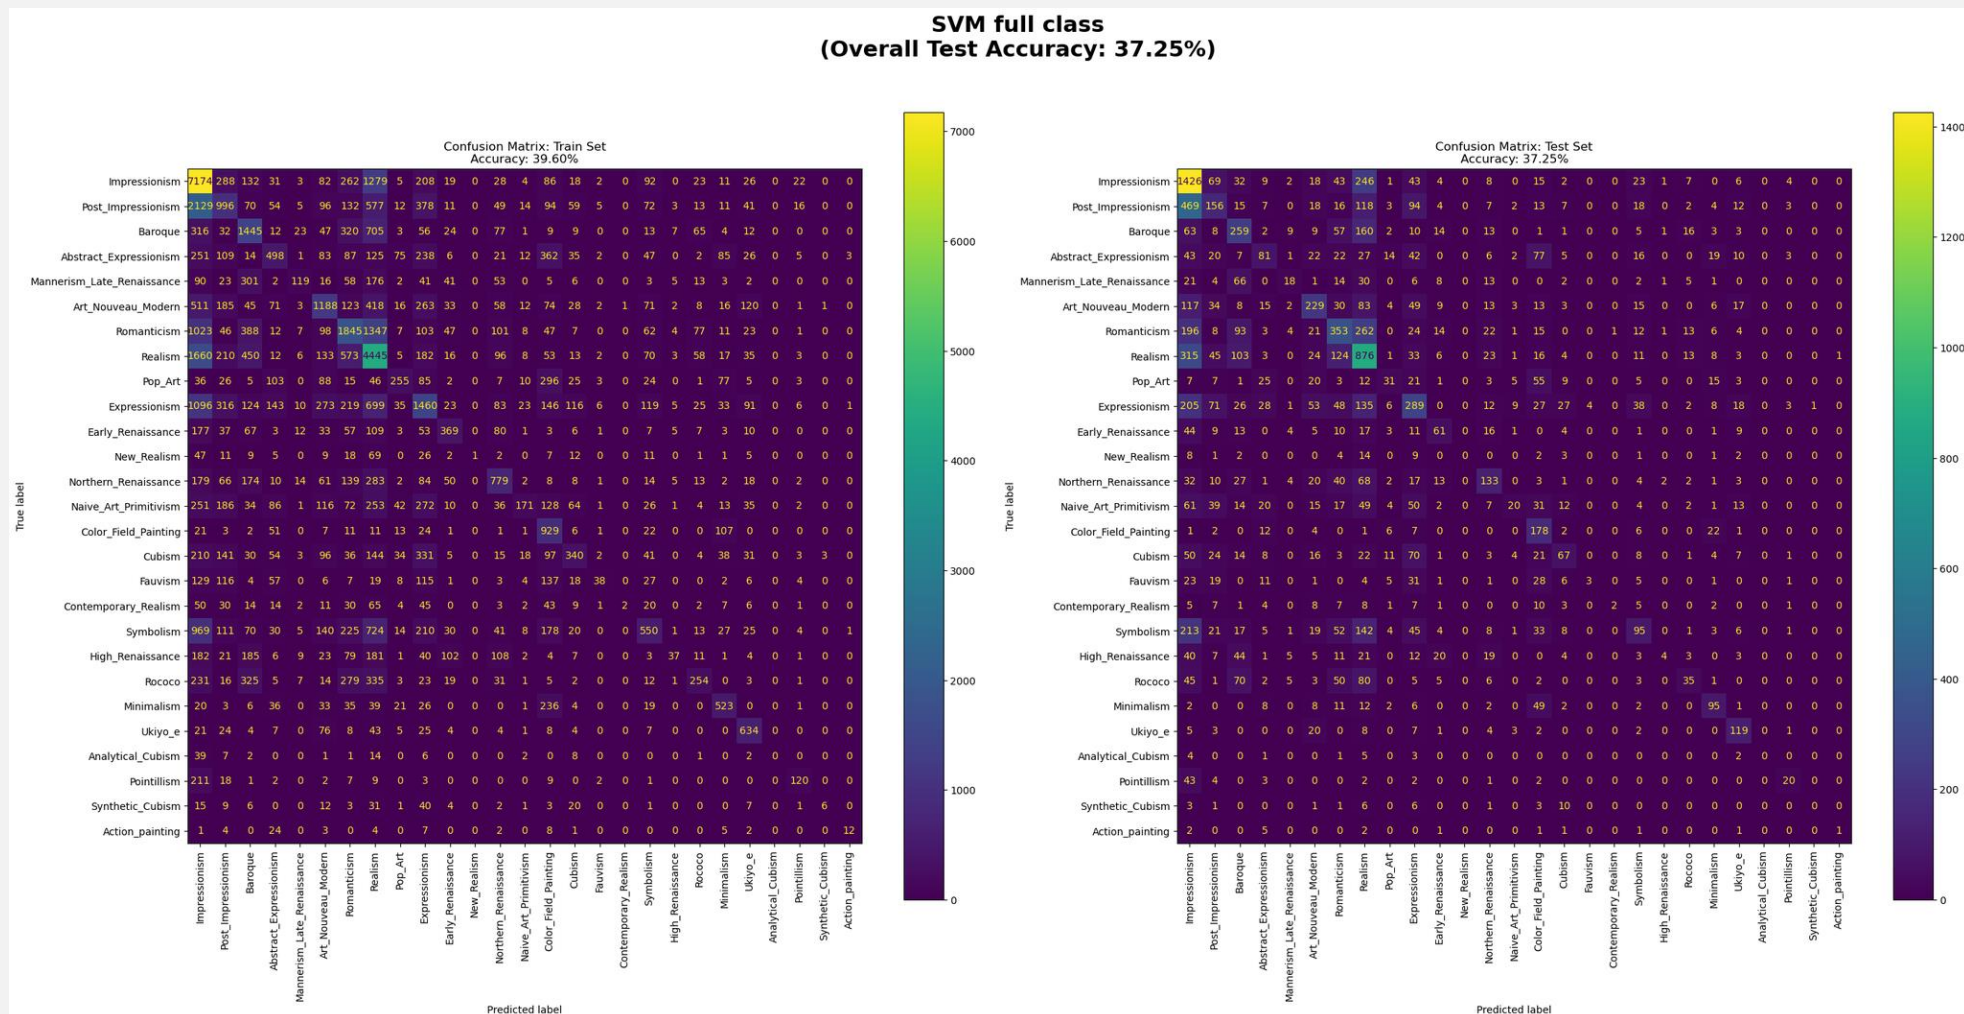
- **Statystyki krawędzi (Edge Statistics)** - wykorzystuje detektor Canny do obliczenia gęstości krawędzi (jaki procent obrazu stanowią linie) oraz filtry Sobela do obliczenia średniej siły (magnitudy) tych krawędzi.
- **Histogram w przestrzeni LAB (LAB Histogram)** - tworzy trójwymiarowy histogram w przestrzeni barw CIELAB (zlicza występowanie kolorów).
- **Analiza teksturowa falkami (Wavelet Texture)** - pozwala określić, czy obraz jest ziarnisty, gładki, czy posiada złożone wzory
- **Estymacja głębi ostrości (Depth of Field Proxy)** - heurystyka mająca na celu symulowanie efektu głębi ostrości (rozmyte tło, ostry obiekt).
- **Analiza kompozycji / Trójpodział (Rule of Thirds Stats)** - kod wycina środkową część obrazu (przecięcie linii trójpodziału) i porównuje statystyki kolorów (HSV) tego obszaru z resztą obrazu

ETAP 2

4 NOWE FILTRY – WSZYSTKIE KLASY

Model A
(Wszystkie klasy):
•**Dokładność**
(Accuracy): **37.25%**

Poprawa o około
0.5 p.p.
w porównaniu do
36.76%




ETAP 2

4 NOWE FILTRY - REDUKCJA LICZBY KLAS

Model B
(Redukcja rzadkich klas
< 2.5%):
•**Dokładność (Accuracy):**
39.42%

Poprawa o około
1.25 p.p.
w porównaniu do
38.17%



ETAP 3



MODYFIKACJA LICZBY FILTRÓW + RFE

Podjęte kroki w tym etapie:

- Dodanie nowych filtrów:
 - **Bag of Visual Words (BoVW)** - częstotliwość występowania charakterystycznych „wizualnych słów” w obrazie
 - **Autokorelogram kolorów** - to cyfrowy opis obrazu, który łączy informację o **kolorze** z informacją o **przestrzeni** (układzie pikseli)
- Zastosowanie **Recursive Feature Elimination** do wyboru optymalnych cech.
 - 10 % rozmiaru zbioru treningowego (optymalizacja czasowa z zachowaniem reprezentatywnej próby)
 - SVM liniowy zamiast RBF
- Dodanie Metryk
 - Top 1, 3, 5 Accuracy
 - Rozkład błędów w przypisywaniu klas

RANKING FILTRÓW

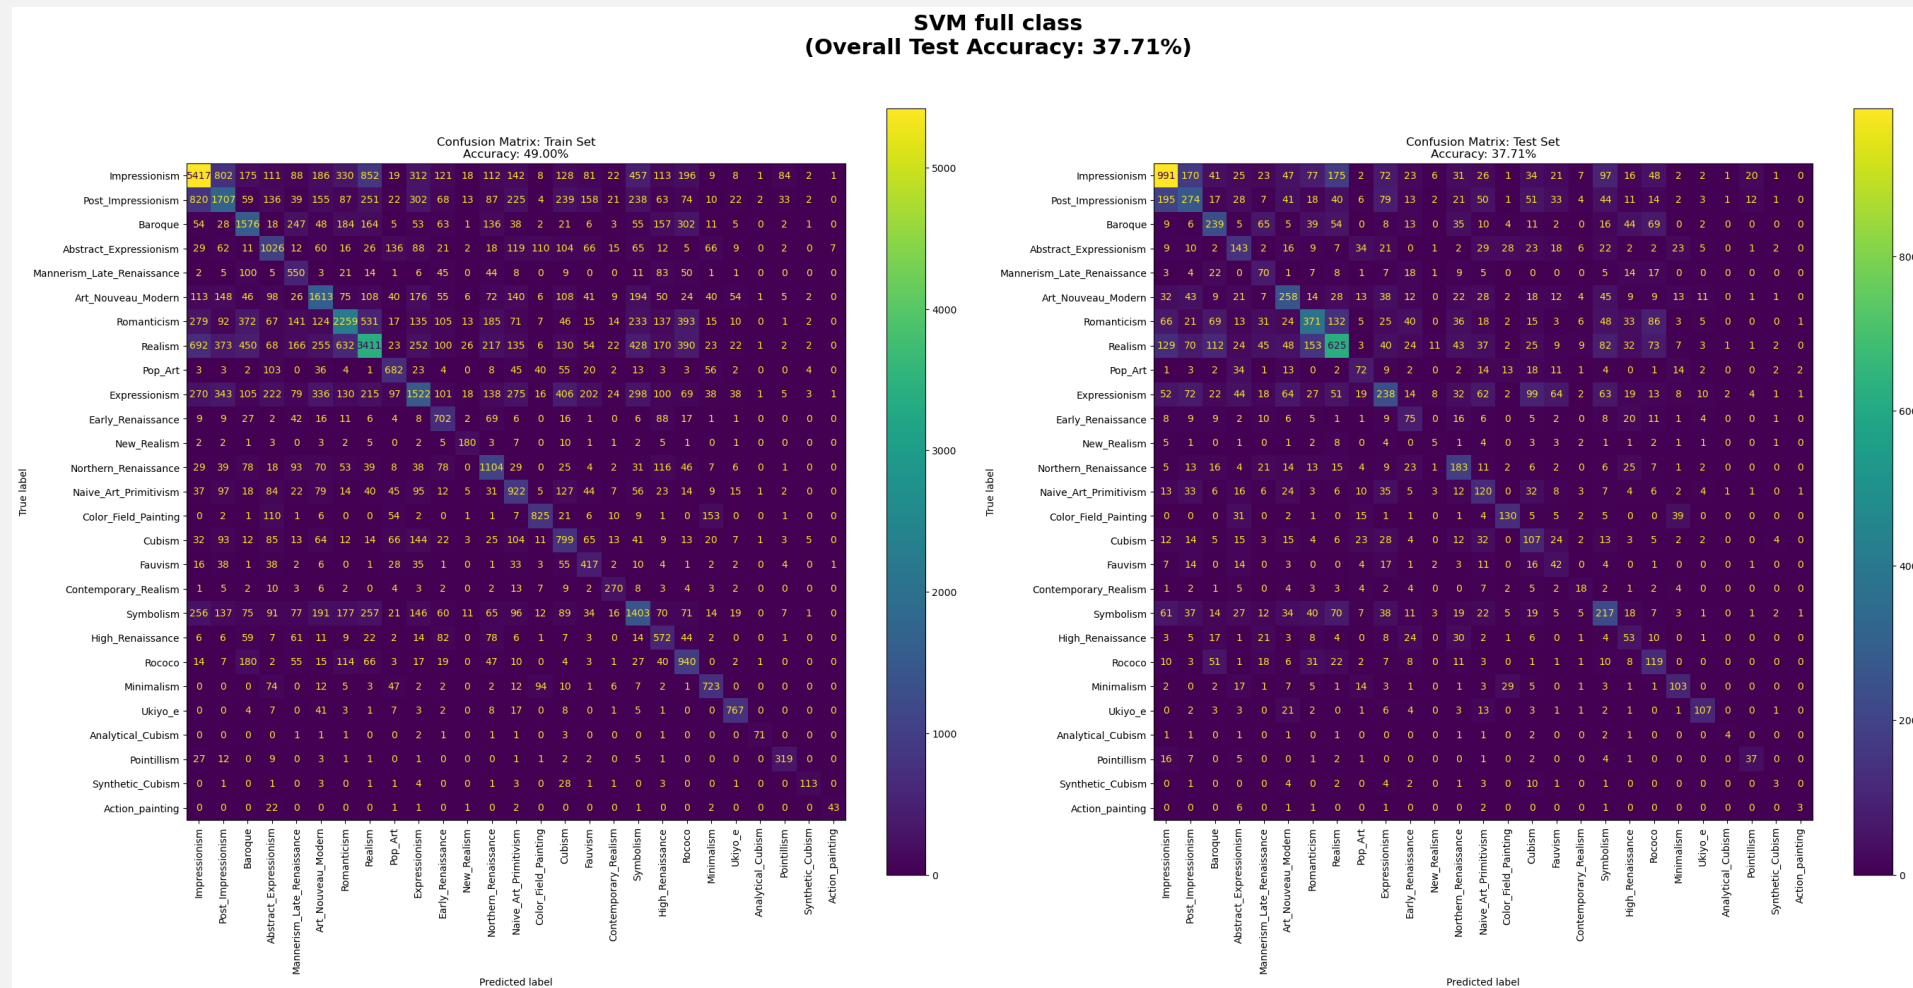
1. Statystyki krawędzi (Edge Statistics)
2. Cechy Haralicka (GLCM)
3. HOG (Histogram of Oriented Gradients)
4. Analiza teksturowa falkami (Wavelet Texture)
5. LBP (Local Binary Patterns)
6. Entropia obrazu (Shannon Entropy)
7. Barwność i Nasycenie (Colorfulness & Saturation)
8. Harmonia i kontrast kolorów
9. Momenty kolorów (Color Moments)
10. Podsumowanie widma radialnego (Spectral Summary)
11. Filtry Gabora
12. Barwność nasycenie z modelu HSV
13. Głębia ostrości (Depth of Field)
14. Bag of Visual Words (BoVW)
15. Autokorelogram kolorów
16. Histogram w przestrzeni LAB (LAB Histogram)



KOŃCOWE WYNIKI – WSZYSTKIE KLASY

Model A
(Wszystkie klasy):
Dokładność (Accuracy):
37.71%

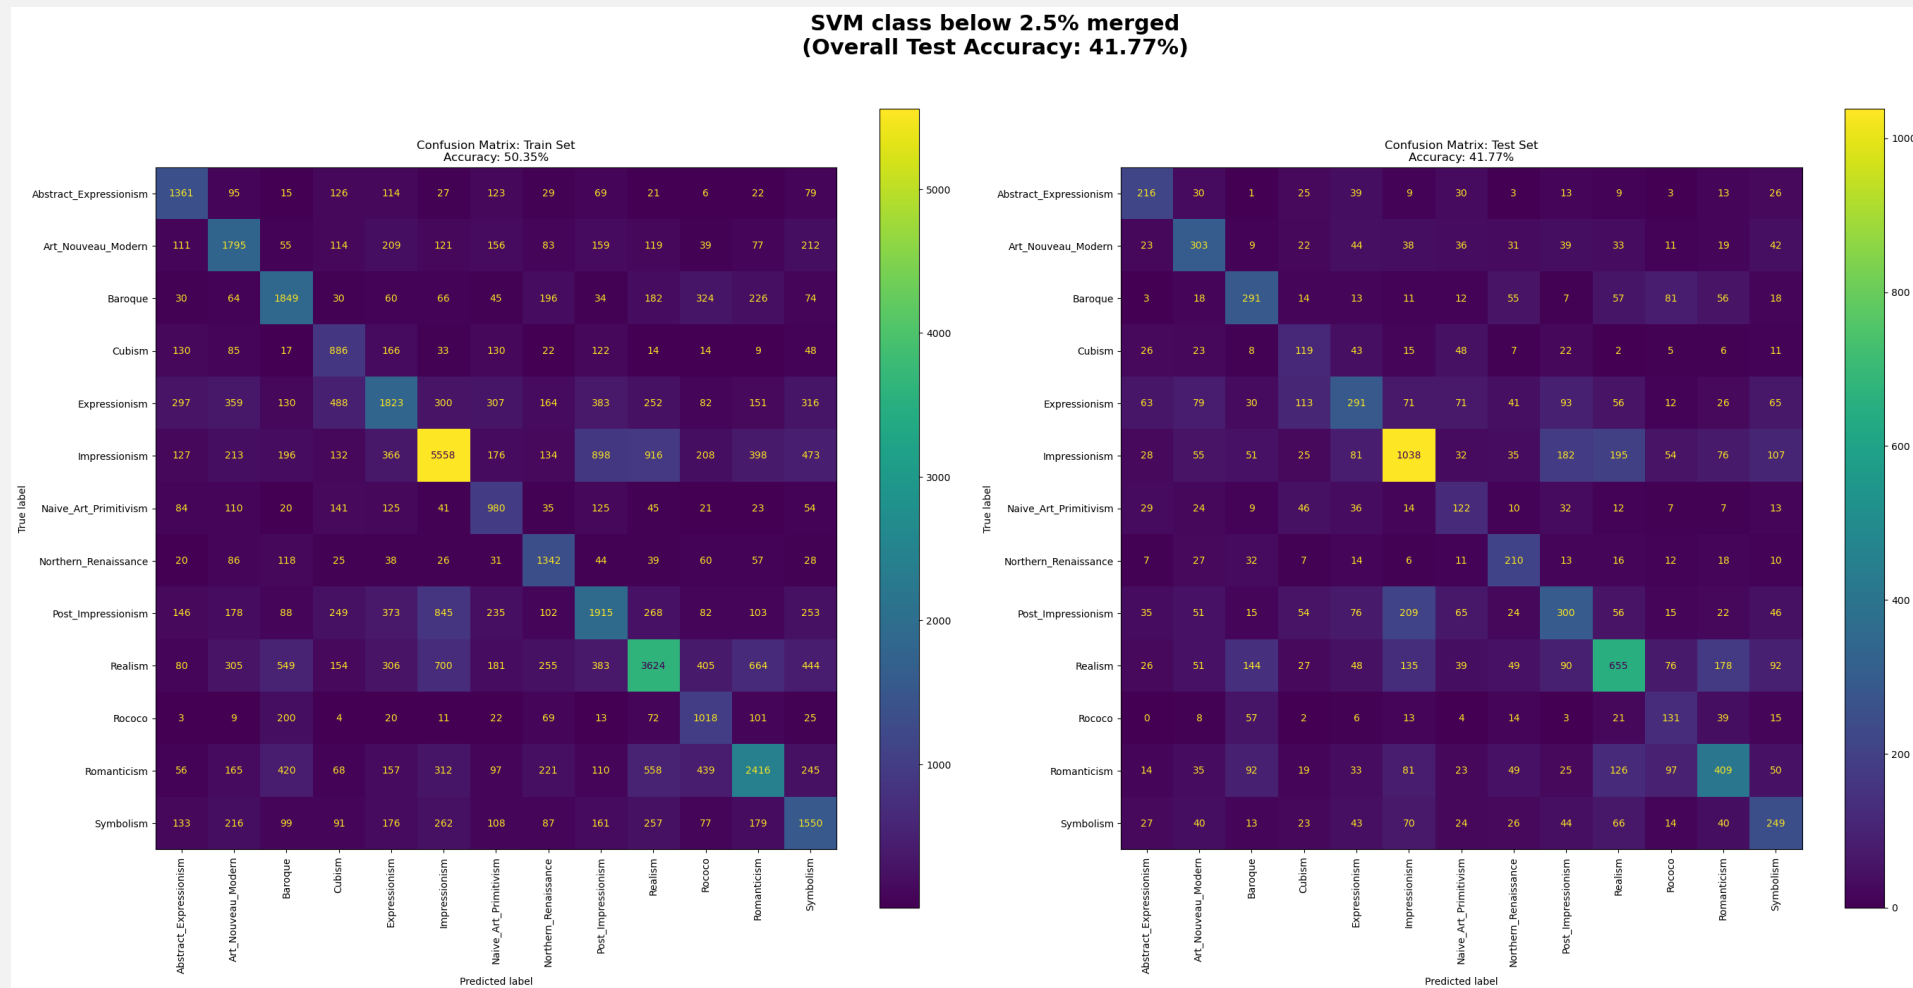
Poprawa o około
0.5 p.p.
w porównaniu do 37.25%



KOŃCOWE WYNIKI – ZREDUKOWANE KLASY

Model B
(Redukcja rzadkich klas
< 2.5%):
**Dokładność (Accuracy):
41.77%**


Poprawa o około 2 p.p.
w porównaniu do 39.42%




KOŃCOWE WYNIKI – WSZYSTKIE KLASY

Analiza Testowa - WikiArt

Skuteczność Top-N




Rozkład błędów




KOŃCOWE WYNIKI – ZREDUKOWANE KLASY

Analiza - Zredukowana Baza (Klasy > 2.5%)

Skuteczność Top-N



Rozkład błędów



WYNIKI W LITERATURZE

Przykładowe wyniki obserwowane w literaturze.

Sieci neuronowe osiągają o wiele wyższą skuteczność

Podejście	Metoda	Accuracy	Źródło
Pojedyncze cechy	Deskryptory (GIST, Classemes, PiCoDes)	~10% – 22%	Saleh & Elgammal (2015)
Fuzja cech (Benchmark)	Multi-Feature Fusion (Low & High Level) + Metric Learning	~39% – 41%	Saleh & Elgammal (2015)
Głębokie sieci	ResNet-50 (Pre-trained)	~65.76%	Zhao et al. (2021)

Saleh, B., i Elgammal, A. (2015). Large-scale classification of fine-art paintings: Learning the right metric on the right feature. <https://doi.org/10.48550/arXiv.1505.00855>

Zhao W, Zhou D, Qiu X, Jiang W (2021) Compare the performance of the models in art classification. PLoS ONE 16(3): e0248414. <https://doi.org/10.1371/journal.pone.0248414>

PORÓWNANIE OBRAZÓW 5 NAJBLIŻSZYCH SĄSIADÓW

ORYGINAŁ
(Realism)



Podobny 1
(Realism)



Podobny 2
(Baroque)



Podobny 3
(Expressionism)



Podobny 4
(Mannerism_Late_Renaissance)



Podobny 5
(Baroque)



ORYGINAŁ
(Color_Field_Painting)



Podobny 1
(Abstract_Expressionism)



Podobny 2
(Color_Field_Painting)



Podobny 3
(Color_Field_Painting)



Podobny 4
(Color_Field_Painting)



Podobny 5
(Color_Field_Painting)




PORÓWNANIE OBRAZÓW 5 NAJBLIŻSZYCH SĄSIADÓW

ORYGINAŁ
(High_Renaissance)



Podobny 1
(Northern_Renaissance)



Podobny 2
(Impressionism)



Podobny 3
(High_Renaissance)



Podobny 4
(High_Renaissance)



Podobny 5
(Romanticism)




ORYGINAŁ
(Impressionism)



Podobny 1
(Realism)



Podobny 2
(Impressionism)



Podobny 3
(Impressionism)



Podobny 4
(Impressionism)



Podobny 5
(Post_Impressionism)



PORÓWNANIE OBRAZÓW 5 NAJBLIŻSZYCH SĄSIADÓW

ORYGINAŁ
(Baroque)



Podobny 1
(Baroque)



Podobny 2
(Baroque)



Podobny 3
(Baroque)



Podobny 4
(Baroque)



Podobny 5
(Baroque)



ORYGINAŁ
(Impressionism)




Podobny 1
(Symbolism)




Podobny 2
(Realism)



Podobny 3
(Impressionism)



Podobny 4
(Impressionism)



Podobny 5
(Impressionism)



PORÓWNANIE OBRAZÓW 5 NAJBLIŻSZYCH SĄSIADÓW

ORYGINAL
(Romanticism)



Podobny 1
(Romanticism)



Podobny 2
(Romanticism)



Podobny 3
(Mannerism_Late_Renaissance)



Podobny 4
(Impressionism)




Podobny 5
(Expressionism)



PODSUMOWANIE

- Dzięki wykorzystaniu **Recursive Feature Elimination** najistotniejszymi filtrami okazały się:
 1. Statystyki krawędzi (Edge Statistics)
 2. Cechy Haralicka (GLCM)
 3. HOG (Histogram of Oriented Gradients)
- Z kolei filtrami które dały najmniejszy wzrost dokładności (ale wciąż były istotne) były:
 11. Filtry Gabora
 12. Barwność nasycenie z modelu HSV
 13. Głębina ostrości (Depth of Field)
- Ekstrakcja cech za pomocą naszych filtrów daje wektory zawierające dość informacji, aby osiągnąć Accuracy **Top-1**, **Top-3** i **Top-5** na poziomach **38%**, **66%** i **80%**.
- Po ekstrakcji wektorów cech różnych obrazów i wzięciu bliskich sobie wektorów (KNN) otrzymujemy bardzo podobne wizualnie obrazy.
- Style powiązane historycznie i wizualnie są mylone (np. *Post-Impressionism* często klasyfikowany jako *Impressionism*) i tradycyjne filtry nie zawsze są w stanie je skutecznie odróżnić.



DZIĘKUJEMY ZA
UWAGĘ :)